#### **ALTA DATABRICKS**



## Try Databricks free

Test-drive the full Databricks platform free for 14 days on your choice of AWS, Microsoft Azure or Google Cloud.

Simplify data ingestion and automate ETL Ingest data from hundreds of sources. Use a simple declarative approach to build data pipelines.

Collaborate in your preferred language
 Code in Python, R, Scala and SQL with coauthoring, automatic versioning, Git integrations and RBAC.

12x better price/performance than cloud data warehouses

See why over 7,000 customers worldwide rely on Databricks for all their workloads

The District All


The Distric





















# Check your email to start your trial.

Thank you for signing up. Please validate your email address to start your trial.

Here are some resources to help you deploy your first workspace.


- $1. \, \underline{\text{Review the administration guide}} \, \text{on the requirements to set up your Databricks service}.$ 
  - o Not an admin on your AWS Account? Share <u>this guide</u> with your admin to deploy a workspace for
- 2. Follow our Quickstart guide to create your first workspace.


You can also check out our **Docs** and **Community** sites to get your questions answered.

Note: if you signed up for Community Edition, you'll go to your first workspace as soon as you verify your email address.


© Databricks 2023. All rights reserved. Apache, Apache Spark, Spark and the Spark logo are trademarks of the <u>Apache Software Foundation.</u> Privacy Policy Terms of Use

# Tras recibir el correo, verificamos con una contraseña y nos pasa directamente a la versión Community.







#### Copiamos el enlace si no lo queremos descargar




https://github.com/databricks-academy/apache-spark-programming-with-databricks/releases/download/v2.2.9/apache-spark-programming-with-databricks-v2.2.9-notebooks.dbc




En Workspace, botón derecho: importar. Y pegamos nuestro enlace.




Tras unos momentos, podemos verlo:



Podemos ya abrir el primero de los archivos sobre el que trabajar.



Necesitamos trabajar con un cluster, que se puede crear desde la pestaña "compute", o el mismo databricks intentará crear uno si se intenta ejecutar una celda (Ctrl+intro). Sino hay ninguno nos "acompañará" en la creación.




En la versión community, los cluster dejan de funcionar a los 20 minutos de inacción, y no es posible volver a arrancarlos. Hay que crear otro nuevo y no hay más problema.


#### Vemos como carga




Para poder usar sql necesitamos que lo reconozca desde Python



## Podemos usar la creación de widget para filtrar en nuestras búsquedas







#### Accedemos a los datos mediante get().




Todos acaban con cleanup() para borrar todo lo creado con el libro.





## **Ejercicio 1**


Comprueba que los archivos "airports.csv" y "flights.csv" están en DBFS




mv("/mnt/my-folder/a", "s3n://bucket/b")
mv("/FileStore/tables/airports\_csv", " FileStore/tables/airports\_csv ")

https://www.youtube.com/watch?v=IOHuO-sbykk

databricks fs mv dbfs:/tmp/my-file.txt dbfs:/parent/child/grandchild/my-file.txt HABILITAR DBFS EN SETTINGS! (hacer un refresh para que se hagan los cambios) Luego ya Podemos subir los archivos.





## %fs ls FileStore

```
O también mediante:
```

```
files = dbutils.fs.ls("dbfs:/FileStore")
display (files)
```

Si hace falta borrar algún fichero subido de más:

```
dbutils.fs.rm("dbfs:/FileStore/flights-1.csv")
```

Pruebo si funcionan las tablas subidas:

Crea los dataframes airports\_df y flights\_df a partir de los ficheros anteriores y muestra las primeras filas y su esquema y comprueba que es el esquema es correcto.

```
# Escribe el código para crear airports_df y flights_df
airports_df = spark.table("airports")
flights_df = spark.table("flights")

# Escribe el código para que muestre las primeras filas(airports_df)
display(airports_df)

# Para mostrar el esquema de airports_df
airports_df.printSchema()

# Escribe el código para que muestre las primeras filas(flights_df)
display(flights_df)

# Para mostrar el esquema de flights_df
flights_df.printSchema()
Ejercicio 2
```

Usando los dataframes anteriores muestra las cinco compañías que más vuelos retrasados tienen (las celdas tiene que ser de tipo Python).

- El campo Carrier contiene la compañía aérea.
- Vamos a considerar que un vuelo llega con retraso cuando el vuelo llega más de 15 minutos tarde (campo ArrDelay > 15).
- El nombre del campo que contine la cuenta de vuelos retrasados se llamará delayed\_flights.

.withColumnRenamed("count", "delayed\_flights")
.orderBy("delayed\_flights", ascending= False)

# Ejercicio 3

)

.count()

.limit(5)

Almacena los dataframes airports\_df y flights\_df en sendas tablas temporales y realiza el ejercicio anterior usando una celda de tipo SQL.

```
# Almacena airports_df en la tabla airports y flights_df en la tabla flights
airports_df.createOrReplaceTempView("airports")
flights_df.createOrReplaceTempView("flights")
%sql
SELECT carrier, COUNT(*) as delayed_flights FROM flights WHERE arrdelay > 15
GROUP BY carrier
ORDER BY delayed_flights DESC LIMIT 5
```

#### Ejercicio 4

Usando los dataframes airports\_df y flights\_df muestra los 5 AEROPUERTOS DE DESTINO que mejor recuperación de tiempo en vuelo tienen (las celdas tienen que ser de tipo Python).

- Se considera que se ha recuperado el tiempo de un vuelo cuando habiendo salido con retraso (DepDelay > 15), llega sin retraso (ArrDelay <= 15).
- Se trata de que muestres los nombres de los 5 aeropuertos de llegada que han recuperado el tiempo en un mayor porcentaje de vuelos que salieron retrasados.

```
display(spark.sql(
   """ SELECT airports.name as Airport, COUNT(CASE WHEN arrdelay <= 15 THEN 1
END) / COUNT(*) as percent_recovered
FROM airports,flights WHERE flights.depdelay > 15 AND airports.airport_id =
flights.DestAirportID GROUP BY airports.name ORDER BY percent_recovered DESC
LIMIT 5 """
)
)
```

```
from pyspark.sql.functions import count, when, col
#SELECT airports.name as Airport, COUNT(CASE WHEN arrdelay <= 15 THEN 1 END)
/ COUNT(*) as percent_recovered
#FROM airports, flights WHERE flights.depdelay > 15 AND airports.airport id =
flights.DestAirportID GROUP BY airports.name ORDER BY percent recovered DESC
LIMIT 5
subquery = (flights_df
            .join(airports_df.select("airport_id", "name"),
col("DestAirportID") == col("airport_id"))
            .filter(col("depdelay") > 15)
            .groupBy("name")
            .agg(count(when(col("arrdelay") <= 15, 1)).alias("recovered"),</pre>
count("*").alias("total"))
            .select("name", (col("recovered") /
col("total")).alias("percent_recovered"))
           )
display(subquery.orderBy("percent_recovered", ascending=False).limit(5))
O Tambien:
display(flights df
        .join(airports_df.select("airport_id", "name"), col("DestAirportID")
== col("airport id"))
        .filter(col("depdelay") > 15)
        .groupBy("name")
        .agg(count(when(col("arrdelay") <= 15, 1)).alias("recovered"),</pre>
count("*").alias("total"))
        .select("name", (col("recovered") /
col("total")).alias("percent_recovered"))
        .orderBy("percent_recovered", ascending=False)
        .limit(5)
       )
```

#### Ejercicio 5

Sube el fichero notas.txt a DBFS y calcula la nota media de cada alumno usando Spark (celdas en Python).

Nota: El fichero notas.txt no tiene estructura de tabla y no vas a poderlo procesar como un Dataframe. Lo recomendable es usar transformaciones y acciones con RDD. En la <u>guía de programación de RDD</u> puedes aprender los conceptos básicos.

Nota2: La implementación debe tener en cuenta que el fichero notas.txt es un simple ejemplo de un fichero más grande que contendría millones de filas. Sin embargo el número de alumnos será de unos cientos.

```
# Comprobamos que notas.txt está en DBFS
files = dbutils.fs.ls("dbfs:/FileStore")
display (files)

# Mostramos el contenido
lines = sc.textFile("dbfs:/FileStore/notas.txt")
f = lines.collect()
for x in f:
    print (x)
```

```
# Leemos el archivo
texts = sc.textFile("dbfs:/FileStore/notas.txt")
# Separamos lineas
lines = texts.map(lambda s: s.split())
# muestra este formato: ['pedro', '6', '7']
# Separamos datos en tupla
students= lines.map(lambda x: (x[0], list(map(int, x[1:])))
#for element in students.collect():
# print(element)
#print(students)
# muestra este formato: ('pedro', [6, 7])
# Convertimos los pares en una lista con el nombre y la nota
list_pairs = students.flatMapValues(lambda x: [(x[i],) for i in
range(len(x))])
#for element in list_pairs.collect():
# print(element)
#print(list_pairs)
# muestra este formato: ('pedro', (6,)('pedro', (7,))
# En el reduce recogemos los datos por nombre y valores
union_data = list_pairs.reduceByKey(lambda x, y: x + y)
#for element in union data .collect():
# print(element)
#print(union data )
# muestra este formato:('pedro', (6, 7, 8, 1, 3))
# Sumamos los datos de las notas y los dividimos entre su longitud para la
sums = union_data.map(lambda x: (x[0], float(sum(x[1]))/len(x[1])))
media = sums.collect()
print(media)
https://www.youtube.com/watch?v=VonQnrSxQWA
https://github.com/databricks-academy/apache-spark-programming-with-databricks/releases
https://learn.microsoft.com/es-es/azure/databricks/getting-started/dataframes-python
https://spark.apache.org/docs/latest/api/python/reference/pyspark.sql/api/pyspark.sql.DataF
rame.withColumnRenamed.html#pyspark.sql.DataFrame.withColumnRenamed
https://sparkbyexamples.com/spark/using-groupby-on-dataframe/
https://sparkbyexamples.com/pyspark/pyspark-flatmap-transformation/
https://databricks-prod-
cloudfront.cloud.databricks.com/public/4027ec902e239c93eaaa8714f173bcfc/313708278187
3852/3704545280501166/1264763342038607/latest.html
https://spark.apache.org/docs/latest/sql-ref-syntax-gry-select.html
https://docs.databricks.com/getting-started/dataframes-python.html
https://docs.databricks.com/dev-tools/databricks-utils.html#file-system-utility-
dbutilsfs&language-python
```

https://spark.apache.org/docs/latest/rdd-programming-guide.html#resilient-distributed-datasets-rdds